

南京工程学院

毕业设计英文翻译

原文名称：Gu L aPA Latent Prompt Assist Model For Medical Visual Question Answering CVPRW 2024 paper converted

姓 名：周健

班 级：人工智能 222

指 导 教 师：王青云

所 在 学 院：通信与人工智能学院、集成电路学院

专 业 名 称：人工智能

2026 年 2 月

LaPA: 用于医学视觉问答的潜在提示辅助模型

Tiancheng Gu

悉尼大学

澳大利亚新南威尔士州悉尼

tigu8498@uni.sydney.edu.au

Kaicheng Yang

DeepGlint

中国北京

kaichengyang@deepglint.com

Dongnan Liu

悉尼大学

澳大利亚新南威尔士州悉尼

dongnan.liu@sydney.edu.au

Weidong Cai

悉尼大学

澳大利亚新南威尔士州悉尼

tom.cai@sydney.edu.au

摘要

医学视觉问答 (Med-VQA) 旨在自动化预测医学图像和问题的正确答案, 从而帮助医生减少重复性任务并减轻他们的工作负担。现有方法主要侧重于使用额外且全面的数据集对模型进行预训练, 然后进行微调以提升下游任务的性能。然而, 探索现有模型以提取临床相关信息同样具有重要价值。在本文中, 我们提出了用于医学视觉问答的潜在提示辅助模型 (LaPA)。首先, 我们设计了一个潜在提示生成模块, 在目标答案的约束下生成潜在提示。随后, 我们提出了一个多模态融合块, 该块带有潜在提示融合模块, 利用潜在提示从单模态和多模态特征中提取临床相关信息。此外, 我们还引入了一个先验知识融合模块, 将疾病和器官之间的关系与临床相关信息相结合。最后, 我们将最终整合的信息与图像-语言跨模态信息相结合, 以预测最终答案。在三个公开可用的Med-VQA数据集上的实验结果表明, LaPA优于最先进的模型ARL, 在VQA-RAD、SLAKE和VQA-2019上的准确率分别提高了1.83%、0.63%和1.80%。代码已公开, 可访问<https://github.com/GaryGuTC/LaPAmode>获取。

1. 引言

医学视觉问答 (Med-VQA) 在疾病检测和诊断中起着至关重要的作用。在临床实践中, 对大量医学图像及其医生提出相应的问题既昂贵又容易出错[16]。为了应对这一挑战, 人们对开发自动 Med-VQA 技术越来越感兴趣[2,6,10,21,24,33]。虽然深度学习模型在通过给定的图像和问题预测标准视觉问答 (VQA) 任务中的准确答案方面取得了显著成功[11,32], 但 Med-VQA 带来了独特的挑战[2]。Med-VQA 数据集的大小相对较小, 由于与医生需要关注的疾病相关的兴

趣区域较小, 医学图像复杂且具有挑战性[8,29]。因此, 从医学图像中提取临床相关信息成为模型的一项艰巨任务[28]。

人们已经提出了许多 Med-VQA 方法[2, 10, 21, 33]来解决上述挑战, 并表现出令人印象深刻的性能。例如, MEVF 模型[24]、MMQ 模型[4]和 cpcr[19]等方法提出了使用外部互补数据集对模型进行预训练以增强模型的分析能力, 然后对下游任务进行微调。同样, M2I2 模型[15]和 m3ae 模型[2]利用自监督学习, 使模型能够从图像和语言两种模式自主学习临床特征。值得注意的是, 尽管这些方法取得了显著的成就, 但它们都没有考虑到潜在的提示。然而, 潜在提示是一个值得关注的方面, 因为它增强了信息提取的灵活性, 在自然语言处理领域的广泛应用证明了这一点[9, 26, 35]。

本研究提出了用于医学视觉问答 (Med-VQA) 的 LaPA (潜在提示辅助) 模型, 如图 1 所示。LaPA 模型结合了潜在提示来过滤不同的模态信息并提取与临床相关的信息, 有助于预测最终答案。首先, 我们介绍潜在提示生成模块, 该模块生成潜在提示。潜在提示与总答案标记进行交互, 并受目标答案标记的约束, 以聚焦于与目标答案相关的标记。随后, 潜在提示被输入到多模态融合模块中, 与单模态和多模态信息进行融合, 从而能够过滤不同模态的信息并提取与临床相关的细节。此外, 潜在提示还与从知识图谱[18]中获得的器官与疾病关系中派生出的先验知识进行交互, 从而生成最终交互信息, 以进一步辅助预测最终答案。最后, 潜在提示与图像-语言跨模态信息相结合, 生成最终答案。




图 1. 我们提出的 LaPA 模型的总体结构。输入特征由带圆角的方框表示，而带方角的结构表示模块。语言和图像管道分别由绿色和蓝色模块表示。蓝色、绿色和红色的最终标记分别对应跨模态图像、语言和综合信息。为获得最佳视觉效果，建议放大以进行详细检查。

我们工作的主要贡献可概括如下：

- 我们提出了潜在提示生成模型，该模型生成潜在提示，并利用多模态融合块过滤不同模态信息并提取临床相关信息。
- 我们利用关于器官和疾病之间关系的先验知识，通过使用图神经网络与潜在提示交互，最终协助答案预测。
- 我们提出的LaPA模型在VQA-RAD[12]、SLAKE[18]和VQA-2019[1]数据集上取得了优异的性能，证明了其有效性。

2. 相关工作

及时学习。及时学习是一个研究重点，旨在利用提示来提高模型性能的各个方面，如效率、灵活性和知识转移[9,37,38]。最近的研究[26,27]探索了利用提示从预训练的模型中提取下游任务的相关信息，并产生了有希望的结果。值得注意的是，[27]提出的 ChatExtract方法采用了工程提示来辅助句子区分和数据提取，从而提高了答案的准确性。相比之下，[35]侧重于使用潜在提示，包括受控和非受控信号，提取有价值 and 高度相关的信息，从而提高文本摘要质量。在这些研究的基础上，我们将潜在提示的概念引入到 Med-VQA 领域。

医学视觉问答。基于医学图像的医学视觉问题答案的自动预测领域已经得到了广泛的研究，产生了许多著名的作品[10,21,24,33]。值得注意的是，已经提出了一些基于外部知识训练模型的方法，例如 MEVF 模型[24]和 MMQ 模型[4]。这些方法使用预先训练的大语言模型 (LLM) 初始化特定模块（例如视觉编码器或解码器）的权重，并随后微调下游 Med-VQA 任务的整体框架。Q2ATransformer [21]引入了一种新颖的方法，结合了分类和生成技术的优点，实现了统一的处理，适用于封闭式和开放式问题。通过采用可学习的候选答案嵌入，Q2ATransformer 针对给定的图像 - 问题对，查询每个答案类别的存在情况。此外，MeDVIInt [34]和 LLaVA-Med [13] 是用于医学视觉问答 (Med-VQA) 理解的生成式模型，它们来自预训练视觉编码器的视觉信息，与大型语言模型 (LLM) 或大型视觉语言模型（如 ChatGPT、LLaVA）进行对齐。与这些现有工作不同，本文所提方法利用潜在提示来过滤单模态和多模态信息，并提取与临床相关的信息，从而优化最终的答案预测过程。




图 2. LaPA 中主要模块的结构如下所示：(a)、(b) 和 (c) 分别表示潜在提示生成模块（3.1 节）、潜在提示融合模块（3.2 节）和先验知识融合模块（3.3 节）。为获得最佳可视化效果，建议放大查看细节。

3.LaPA模型

图 1 展示了本文所提出的LaPA（Latent Prompt Assist，潜在提示辅助）医学视觉问答模型的整体架构。

该模型包含三个核心组件：潜在提示生成模块（3.1 节）、多模态融合模块（3.2 节）以及先验知识融合模块（3.3 节）。关于训练过程的更多细节将在 3.4 节中详细阐述。

3.1. 潜在提示生成模块

我们首先提出**潜在提示生成模块**（图 2 (a)），用于生成**可学习潜在提示**，该提示采用正态分布进行初始化。为提升训练效率与模型性能，我们将生成的潜在提示与**全部答案词元（answer tokens）**进行交互。在答案词元的约束下，潜在提示能够聚焦于与答案相关的词元。为此，我们将下游数据集集中的所有答案词元视作先验知识，并利用 **RoBERTa [20]** 将其编码为特征 **X_{TA}**。随后，全部答案词元经过自注意力机制与投影层，得到总词元特征 **F_{TA}**，计算公式如下：

$$F_{TA} = \text{Proj}(\text{SA}(X_{TA})), \quad (1)$$

其中 **SA(·)** 和 **Proj(·)** 分别表示自注意力机制和投影层。随后，我们采用交叉注意力将全部答案词元与潜在提示进行融合：

$$\hat{X}_{LP} = \text{CA}(X_{LP}, F_{TA}, F_{TA}) \quad (2)$$

其中 **CA(·)** 表示以查询、键、值为输入的交叉注意力机制[30]。为聚焦于与答案相关的词元，我们引入一致性损失 **LCS**，利用目标答案对潜在提示进行约束，使其在语义空间中更贴近目标答案。该过程定义如下：

$$L_{CS}(\hat{X}_{LP}, X_A) = 1 - \frac{\hat{X}_{LP}^T X_A}{\|\hat{X}_{LP}\| \|X_A\|} \quad (3)$$

其中 **XA** 表示目标答案的词嵌入（token embeddings）

3.2. 多模态融合模块

为了使隐式提示能够从单模态和多模态信息中充分提取临床相关信息，我们引入了一个多模态特征融合模块。如图 1 所示，图像特征与语言特征分别由 **Swin Transformer [22]** 和 **RoBERTa [20]** 提取，通过自注意力操作可得到单模态特征 **F_I** 和 **F_L**，具体如下：

$$F_I = \text{SA}(E_I(X_I)), \quad (4)$$

$$F_L = \text{SA}(E_L(X_L)). \quad (5)$$

之后，通过**交叉注意力**对图像特征和语言特征进行融合，得到多模态特征 **F_{MM}**：

$$F_{MM} = [\text{Proj}(\text{CA}(F_I, F_L, F_L)); \text{Proj}(\text{CA}(F_L, F_I, F_I))], \quad (6)$$

其中 **Proj(·)** 表示投影层。

在得到单模态与多模态特征 **F_I**、**F_L** 和 **F_{MM}** 之后，我们设计了**隐式提示分裂模块**（图 2 (b)），使得隐式提示通过**交叉注意力**融合临床相关信息：

$$X_{II} = \text{CA}(\hat{X}_{LP}, F_I, F_I) \quad (7)$$

$$X_{II} = \text{CA}(X_{II}, F_L, F_L) \quad (8)$$

$$X_{II} = \text{CA}(X_{II}, F_{MM}, F_{MM}) \quad (9)$$

其中， $CA(\cdot)$ 为交叉注意力机制。 X^{Π} 表示将隐式提示与图像特征相结合后得到的融合信息。同理， $X^{\sim\Pi}$ 与 $X^{\sim\Pi}$ 分别表示语言特征与多模态特征融合后得到的集成信息。该融合过程遵循时序顺序：先融合语言特征，再融合图像特征，最后融合多模态特征。我们通过实验探究了多种信息融合与提取方式，当前结构取得了最优效果。

在多模态融合模块中，利用隐式提示与语言特征进行融合，以在文本语义空间内提取临床相关信息。随后，将其与图像特征结合，在图像语义空间内提取临床相关信息。最后，将上述集成信息与语言-图像交叉模态特征进一步融合，筛选出不同模态信息，并对文本、图像的单模态特征及其多模态融合特征进行整合，最终生成最终的临床相关信息。

3.3 先验知识融合模块

在已有工作 [31,36] 的基础上，我们引入了先验知识图 [18]，该图能够捕捉器官与疾病之间的关联，从而提升医学视觉问答（Med-VQA）中答案预测的准确性。我们采用图神经网络（GNN (·)）来分析器官 - 疾病关系，并提升答案预测的性能。此外，我们提出了一种先验知识融合模块，通过整合先验知识与集成信息来辅助最终的答案预测。

如图 2 (c) 所示，邻接矩阵 X_{adj} 由上述先验知识 [18] 推导得到，采用二进制数值（0 和 1）表示器官与疾病之间的关联关系。器官-疾病特征 F_{OD} 经 RoBERTa [20] 进行分词与嵌入后，输入至图神经网络（GNN）模块，以提取器官-疾病关联的有效信息，记为 FG ，具体过程可表示如下：

$$FG=GNN(F_{OD},X_{adj}). \tag{10}$$

随后，将提取到的信息与之前得到的集成信息 X_{LP} 进行融合，得到最终的集成信息 X^{Π} ，具体过程如下：

$$X^{\Pi}=[\tilde{X}^{\Pi};Proj(CA(F_G,X_{LP},X_{LP}))], \tag{11}$$

其中， $CA(\cdot)$ 为交叉注意力机制（cross-attention mechanism）， $Proj(\cdot)$ 为投影层（projection layer）。最后，将基于交互关系的特征与隐式提示进行拼接（拼接操作记为 $[·]$ ），作为最终的集成信息，以辅助医学视觉问答（Med-VQA）任务的最终答案预测。

3.4.训练细节

经过上述所有过程后，我们将最后一个多模态融合模块中交叉模态注意力的交叉模态信息 F_{FI} 和 F_{FL} ，与最终的集成信息 X^{Π} 相结合，用于答案预测，具体如下：

$$X_F=\alpha X^{\Pi}+\theta F_{FI}+\beta F_{FL}, \tag{12}$$

其中， α 、 θ 和 β 均为权重系数，用于平衡不同类型的信息。最终的总损失（记为 LT ）如下所示：

$$L_T=L_{BCE}(X_F,F_T)+\eta L_{CS}, \tag{13}$$

其中，LBCE 表示二元交叉熵损失[7]，LCS 表示一致性损失，该损失用于最小化隐式提示与目标答案之间的语义距离。 η 为损失权重，用于调节不同损失项的影响程度。

4. 实验与结果

4.1实现细节

在我们的模型中，我们采用 Swin-Transformer [22] 作为图像提取模型，采用 RoBERTa [20] 作为语言提取模型，采用图注意力网络（graph attention network, GAT）[31]。

方法	期刊	VQA-RAD			SLAKE			VQA-2019 整体表现
		打开	关闭	表现	打开	关闭	表现	
BAN[11]	NeurIPS18	37.40	72.10	58.30	74.60	79.10	76.30	-
CPRD-BAN[17]	MICCAI21	52.50	77.90	67.80	79.50	83.40	80.10	-
MMBERT[10]	ISBI21	63.10	77.90	72.00	-	-	-	67.20
M3AE*†[2]	MICCAI22	64.80	82.72	75.61	79.22	85.10	81.53	78.40
M2I2[15]	ISBI22	61.80	81.60	73.70	74.70	91.10	81.20	-
ARL*[3]	MM22	65.10	85.96	77.55	79.70	89.30	84.10	79.80
PubMedCLIP[5]	EACL23	60.10	80.00	72.10	78.40	82.50	80.10	-
CPCR[19]	TMI23	60.50	80.40	72.50	80.50	84.10	81.90	-
LaPA	Ours	68.7	86.40	79.38	82.17	88.70	84.73	81.60

表格 1. LaPA 模型与其他对比模型在 VAR-RAD、SLAKE 和VQA-2019 数据集上的实验结果* 表示该结果为本文自行测试所得，可能与原论文报道结果存在差异。†表示基线模型。其余模型结果均取自其原论文。为清晰展示，每一类中性能最优的结果已用粗体标出。

#	方法	VQA-RAD			SLAKE			VQA-2019 整体表现
		打开	关闭	表现	打开	关闭	表现	
1	BL.	64.80	82.72	75.61	79.22	85.10	81.53	78.40
2	+GM. <i>w/ocs</i> &LF.	68.16	84.93	78.27	80.93	87.74	83.60	80.80
3	+GM.&LF.	69.27	85.29	78.94	81.24	87.50	83.70	81.30
4	+GM.&LF.+PF.	68.72	86.40	79.38	82.17	88.70	84.73	81.60
-	Δ	13.92	13.68	13.77	12.95	13.60	13.20	13.20

表 2. 我们在 VQA-RAD、SLAKE 和 VQA-2019 数据集上对 LaPA 模型进行了消融实验，以确定各个组件对整体性能的贡献。其中，GM、LF 和 PF 分别表示隐式提示生成模块、隐式提示融合模块和先验知识融合模块。*w/o cs* 表示在模型结构中移除了一致性方法。最后一行给出了 LaPA 模型相对于基线模型的性能提升情况。

采用8头注意力的图神经网络模型，并使用6个多模态融合模块。在单块24GB显存的NVIDIA GeForce RTX 3090 GPU上开展训练，并采用半精度训练方式。参照M3AE[2]的设置，本文使用AdamW优化器[23]进行优化，学习率设置为5e-6。输入图像被缩放至384×384大小，特征维度设为768。此外，我们使用了在ROCO[25]和MediCaT[28]数据集上预训练的M3AE模型权重。在评估阶段，本文分别报告闭集问题与开集问题的匹配准确率，整体指标按照M3AE[2]中的方式，通过加权系数融合开集与闭集问题的结果计算得到。

4.2.数据集

为全面评估所提方法的有效性，本文在三个广泛使用的医学视觉问答基准数据集上开展实验，分别为VQA-RAD [12]、SLAKE [18] 与 VQA-2019 [1]。实验中采用了 M3AE [2] 等现有工作提供的数据集划分方式。VQA-RAD 与 SLAKE 数据集中的问题分为两类：开放性问题（自由形式）与封闭式问题（是 / 否形式）。VQA-

RAD 数据集包含 315 张放射学图像，共计 3064 个问答对，其中 451 个问答对作为测试集。SLAKE 数据集由 642 张放射学图像构成，包含 14028 个问答对，并按照 70:15:15 的比例划分为训练集、验证集与测试集。值得注意的是，本文仅在 SLAKE 的英文子集上进行评估。VQA-2019 数据集包含 3200 张医学图像，其中训练集有 12792 个问答对，验证集包含 500 张图像与 2000 个问答对，测试集包含 500 张图像与 500 个问答对。

4.3.对比实验

本文将所提出的 LaPA 模型与八种当前主流的先进（SOTA）方法进行了对比，包括 BAN [11]、CPRD [17]、MMBERT [10]、M3AE [2]、M2I2 [15]、ARL [3]、PubMedCLIP [5] 以及 CPCPR [19]。如表 1 所示，LaPA 模型在三个数据集上的多数评估指标均稳定优于上述模型。




Figure3. 对超参数 θ 和 β 的消融实验。

InteractOrder	VQA-RAD			SLAKE			VQA-2019 整体表现
	打开	关闭	表现	打开	关闭	表现	
I. $\Rightarrow$ L. $\Rightarrow$ MM.	55.31	84.56	72.95	81.40	87.74	83.88	78.93
L. $\Rightarrow$ I. $\Rightarrow$ MM.	68.72	86.40	79.38	82.17	88.70	84.73	81.60

表 3. 隐式提示融合模块中隐式提示在不同融合方向下的实验结果。其中，I、L 和 MM 分别是图像（image）、语言（language）和多模态（multi-modal）的缩写。

隐式提示长度	4	8	16	32	64	128	256
VQA-RAD	77.16	78.27	78.49	79.38	76.94	76.49	75.61
SLAKE	84.17	84.35	83.88	84.73	84.26	84.26	84.45
VQA-2019	80.00	80.53	79.47	81.60	79.47	78.93	80.00

表 4. 隐式提示长度的消融实验。

值得注意的是，在 VQA-RAD 数据集上，本文模型在各类问题上均取得了显著的性能提升，**综合准确率**达到 **79.38%**，较第二名模型提升 1.83 个百分点。在 SLAKE 数据集上，LaPA 的**综合准确率为 84.73%**，领先第二名约 0.63 个百分点。在 VQA-2019 上，本文模型取得了**81.6% 的综合准确率**，较第二名提升 1.8 个百分点。

M2I2 模型在处理封闭式问题时表现较好，但在开放式问题上存在明显不足，这可能与其预训练数据集的差异有关。由于代码、权重及预训练数据集未公开，难以复现实验结果，因此 Q2ATransformer [21] 和 MUMC [14] 未纳入对比。此外，MeDVInT [34] 和 LLaVA-Med [13] 的参数量均超过 70 亿，约为 LaPA 模型（0.405 亿）的 17 倍。尽管这类大模型在部分指标上表现更优，但由于模型规模与复杂度差距过大，对比不具备公平性，因此也未纳入对比分析。

4.4. 消融实验

本节中，我们开展了消融实验，以评估所提方法中各个模块的影响。实验结果总结在表 2 中，涵盖了三个基准数据集。我们使用以下缩写：BL 表示基线模型，GM 表示隐式提示生成模块（详见 3.1 节），LF 表示隐式提示融合模块（详见 3.2 节），PF 表示先验知识融合模块（详见 3.3 节）。符号 w/o cs 表示未使用一致性方法的模型结构，用于验证其有效性。最后一行给出了 LaPA 模型相较于基线模型的性能提升。

由于隐式提示生成模块与图像和语言模态为间接交互，我们通过结合 GM 与 LF 模块进行消融实验来分析其作用。表 2 中 #1 与 #2 条件的对比表明

η	0.01	0.05	0.1	0.5	1
VQA-RAD	71.84	72.28	79.38	72.28	72.95
SLAKE	83.69	83.60	84.73	83.22	83.60
VQA-2019	80.27	78.40	81.60	78.40	80.80

表 5. 关于 η 的消融实验

隐式提示的加入显著增强了模型处理医学视觉问答任务的能力。进一步，我们验证了一致性方法的有效性，条件#3相较于#2的性能提升证明了其作用。加入先验知识融合模块后，模型性能得到进一步提升（对比#4与#3）。最终，在基线模型中融合所有改进模块后，如条件#5所示，模型性能实现了大幅提升。消融实验最后一行显示，相比于基线模型，本文方法在三个数据集上的整体提升接近3%。

对超参数 θ 和 β 的消融实验。超参数 θ 和 β 在调节跨模态信息交互中起着关键作用，进而影响最终预测结果的准确率。图3使用三组热力图展示了不同 θ 和 β 系数对三个基准数据集中图像与语言跨模态特征融合的影响。在将隐式提示系数 α 固定为1、隐式提示

长度固定为32的情况下，我们将 θ 和 β 从0.01、0.1逐步调整至1，系统地评估其对模型性能的影响。图3中的可视化结果表明， $\beta=0.1$ 且 $\theta=0.1$ 的组合在所有三个

评测数据集上均为最优。交互顺序的消融实验

隐式提示融合模块内部的交互顺序，直接影响通过隐式提示进行信息提取的效果。表 3 展示了不同融合顺序对最终输出准确率的影响。实验观察到，最优的融合顺序为：先处理语言模态，再融入图像模态，最后进行多模态融合，该方式能够取得最佳效果。

隐式提示长度的消融实验。隐式提示长度直接决定了隐式提示框架内的参数量。表 4 分析了将隐式提示长度从 4 调整到 256 时，模型在三个基准数据集上的性能变化。起初，随着隐式提示长度的增加，模型在各数据集上的性能随之提升；但当长度超过 32 时，模型准确率开始下降。实验结果表明，当隐式提示长度为 32 时，模型在所有评测数据集上均达到最优性能。我们推测，过大的隐式提示维度会在信息提取过程中引入冗余且具有干扰性的噪声，从而降低医学视觉问答任务最终答案预测的精度。

关于 η 的消融实验。超参数 η 直接影响总损失函数中一致性损失的权重。表 5 展示了将 η 从 0.01 调整到 1 时，模型在三个基准数据集上整体性能的变化。实验结果表明，将 η 设置为 0.01 时，在所有三个数据集上均能取得最优效果。

4.5 定性分析

为进一步验证本文提出的隐式提示辅助模型（LaPA）的有效性，我们对六个医学视觉问答（Med-VQA）示例进行了定性分析，其中三个示例来自 VQA-RAD 数据集（案例 a、b、c），三个来自 SLAKE 数据集（案例 d、e、f），如图 4 所示。从案例 a、b、c、d、f 可以看出，引入隐式提示能够帮助模型在两个数据集上准确回答封闭式与开放式问题。但在案例 e 中，仅依靠隐式提示不足以让模型区分两个高度相似的答案；而加入先验知识融合模块（PF.）后，有效修正了模型的输出结果。上述六个案例共同表明，本文提出的改进策略能够显著提升模型在处理封闭式与开放式视觉问答任务时的性能。

5. 结论

本研究提出一种新颖的**隐式提示辅助模型**（LaPA），旨在提升医学视觉问答（Med-VQA）领域的回答准确率。

该模型利用隐式提示对不同模态信息进行筛选，并提取与临床相关的信息，以辅助最终答案的预测。本文提出的创新框架包含一个隐式提示生成模块，该模块在目标答案标记的约束下合成隐式提示。随后，将这些提示与单模态和多模态信息流相融合，以提取关键临床信息。此外，模型

还引入了封装在知识图谱中的先验知识（疾病—器官关联关系），与隐式提示进行交互，从而优化最终的答案预测。

在三个经典基准数据集上的实验结果表明，本文方法在医学视觉问答任务中能够生成更准确的答案，具有显著优势。未来，我们计划将隐式提示机制应用于大规模、高参数量的模型中，以充分挖掘隐式提示在复杂推理任务中的潜力。




图 4. LaPA 模型使用不同模块进行消融实验的六个示例。样本 a、b、c 取自 VQA RAD 数据集，样本 d、e、f 取自 SLAKE 数据集。图中，绿色标注表示模型预测正确，红色标注表示模型预测错误。GM.、LF.、PF. 分别为隐式提示生成模块、隐式提示融合模块和先验知识融合模块的缩写。

参考文献

- [1] Asma Ben Abacha, Sadid A Hasan, Vivek V Datla, Joey Liu, Dina Demner-Fushman, and Henning Müller. Vqa-med: Overview of the medical visual question answering task at imageclef 2019. *CLEF (working Notes)*, 2(6), 2019. 2, 5
- [2] Zhihong Chen, Yuhao Du, Jinpeng Hu, Yang Liu, Guanbin Li, Xiang Wan, and Tsung-Hui Chang. Multi-modal masked autoencoders for medical vision-and-language pre-training. In *International Conference on Medical Image Computing and Computer-Assisted Intervention*, pages 679–689. Springer, 2022. 1, 5
- [3] Zhihong Chen, Guanbin Li, and Xiang Wan. Align, reason and learn: Enhancing medical vision-and-language pre-training with knowledge. In *Proceedings of the 30th ACM International Conference on Multimedia*, pages 5152–5161, 2022. 5
- [4] Tuong Do, Binh X Nguyen, Erman Tjiputra, Minh Tran, Quang D Tran, and Anh Nguyen. Multiple meta-model quantifying for medical visual question answering. In *Medical Image Computing and Computer Assisted Intervention MICCAI 2021: 24th International Conference, Strasbourg, France, September 27–October 1, 2021, Proceedings, Part V 24*, pages 64–74. Springer, 2021. 1, 2
- [5] Sedigheh Eslami, Gerard de Melo, and Christoph Meinel. Does clip benefit visual question answering in the medical domain as much as it does in the general domain? arXiv preprint arXiv:2112.13906, 2021. 5
- [6] Haifan Gong, Guanqi Chen, Mingzhi Mao, Zhen Li, and Guanbin Li. Vqamix: Conditional triplet mixup for medical visual question answering. *IEEE Transactions on Medical Imaging*, 41(11):3332–3343, 2022.
- [7] Irving John Good. Rational decisions. *Journal of the Royal Statistical Society: Series B*, 14(1):107–114, 1952. 4
- [8] Tiancheng Gu, Dongnan Liu, Zhiyuan Li, and Weidong Cai. Complex organ mask guided radiology report generation. In *Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision*, pages 7995–8004, 2024. 1
- [9] Yuxian Gu, Xu Han, Zhiyuan Liu, and Minlie Huang. PPT: Pre-trained prompt tuning for few-shot learning. In Smaranda Muresan, Preslav Nakov, and Aline Villavicencio, editors, *Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, 2022. 1, 2
- [10] Yash Khare, Viraj Bagal, Minesh Mathew, Adithi Devi, U Deva Priyakumar, and CV Jawahar. Mmbert: Multi modal bert pretraining for improved medical vqa. In *2021 IEEE 18th International Symposium on Biomedical Imaging*, pages 1033–1036. IEEE, 2021. 1, 2, 5
- [11] Jin-Hwa Kim, Jaehyun Jun, and Byoung-Tak Zhang. Bilinear Attention Networks. In *Advances in Neural Information Processing Systems 31*, pages 1571–1581, 2018. 1, 5
- [12] Jason J Lau, Soumya Gayen, Asma Ben Abacha, and Dina Demner-Fushman. A dataset of clinically generated visual questions and answers about radiology images. *Scientific data*, 5(1):1–10, 2018. 2, 5
- [13] Chunyuan Li, Cliff Wong, Sheng Zhang, Naoto Usuyama, Haotian Liu, Jianwei Yang, Tristan Naumann, Hoifung Poon, and Jianfeng Gao. Llava-med: Training a large language and-vision assistant for biomedicine in one day. *Advances in Neural Information Processing Systems*, 36, 2024. 3, 6
- [14] Pengfei Li, Gang Liu, Jinlong He, Zixu Zhao, and Shenjun Zhong. Masked vision and language pre-training with uni modal and multimodal contrastive losses for medical visual question answering. In *International Conference on Medical Image Computing and Computer-Assisted Intervention*, pages 374–383. Springer, 2023. 6
- [15] Pengfei Li, Gang Liu, Lin Tan, Jinying Liao, and Shenjun Zhong. Self-supervised vision-language pretraining for medical visual question answering. In *2023 IEEE 20th International Symposium on Biomedical Imaging*, pages 1–5. IEEE, 2023. 1, 5
- [16] Zhihong Lin, Donghao Zhang, Qingyi Tao, Danli Shi, Ghulamreza Haffari, Qi Wu, Mingguang He, and Zongyuan Ge. Medical visual question answering: A survey. *Artificial Intelligence in Medicine*, page 102611, 2023. 1
- [17] Bo Liu, Li-Ming Zhan, and Xiao-Ming Wu. Contrastive pre-training and representation distillation for medical visual question answering based on radiology images. In *Medical Image Computing and Computer Assisted Intervention MICCAI 2021: 24th International Conference, Strasbourg, France, September 27–October 1, 2021, Proceedings, Part II 24*, pages 210–220. Springer, 2021. 5
- [18] Bo Liu, Li-Ming Zhan, Li Xu, Lin Ma, Yan Yang, and Xiao-Ming Wu. Slake: A semantically-labeled knowledge enhanced dataset for medical visual question answering. In *2021 IEEE 18th International Symposium on Biomedical Imaging*, pages 1650–1654. IEEE, 2021. 2, 4, 5
- [19] Bo Liu, Li-Ming Zhan, Li Xu, and Xiao-Ming Wu. Medical visual question answering via conditional reasoning and contrastive learning. *IEEE transactions on medical imaging*, 42(5):1532–1545, 2022. 1, 5
- [20] Yinhan Liu, Myle Ott, Naman Goyal, Jingfei Du, Mandar Joshi, Danqi Chen, Omer Levy, Mike Lewis, Luke Zettlemoyer, and Veselin Stoyanov. Roberta: A robustly optimized bert pretraining approach. arXiv preprint arXiv:1907.11692, 2019. 3, 4

- [21] Yunyi Liu, Zhanyu Wang, Dong Xu, and Luping Zhou. Q2atransformer: Improving medical vqa via an answer querying decoder. In International Conference on Information Processing in Medical Imaging, pages 445–456. Springer, 2023. 1, 2, 6
- [22] Ze Liu, Yutong Lin, Yue Cao, Han Hu, Yixuan Wei, Zheng Zhang, Stephen Lin, and Baining Guo. Swin transformer: Hierarchical vision transformer using shifted windows. In Proceedings of the IEEE/CVF International Conference on Computer Vision, 2021. 4
- [23] Ilya Loshchilov and Frank Hutter. Decoupled weight decay regularization. In ICLR, 2018. 5
- [24] Binh D Nguyen, Thanh-Toan Do, Binh X Nguyen, Tuong Do, Erman Tjiputra, and Quang D Tran. Overcoming data limitation in medical visual question answering. In Medical Image Computing and Computer Assisted Intervention MICCAI 2019: 22nd International Conference, Shenzhen, China, October 13–17, 2019, Proceedings, Part IV 22, pages 522–530. Springer, 2019. 1, 2
- [25] Obioma Pelka, Sven Koitka, Johannes R’uckert, Felix Nensa, and Christoph M Friedrich. Radiology objects in context (roco): a multimodal image dataset. In Intravascular Imaging and Computer Assisted Stenting and Large-Scale Annotation of Biomedical Data and Expert Label Synthesis: 7th Joint International Workshop, CVII-STENT 2018 and Third International Workshop, LABELS 2018, Held in Conjunction with MICCAI 2018, Granada, Spain, September 16, 2018, Proceedings 3, pages 180–189. Springer, 2018. 5
- [26] Jiaren Peng, Wenzhong Yang, Fuyuan Wei, and Liang He. Prompt for extraction: Multiple templates choice model for event extraction. Knowledge-Based Systems, page 111544, 2024. 1, 2
- [27] Morgan D. Polak, M.P. Extracting accurate materials data from research papers with conversational language models and prompt engineering. Nat Commun 15, 1569 (2024)., 2024. 2
- [28] Sanjay Subramanian, Lucy Lu Wang, Sachin Mehta, Ben Bogin, Madeleine van Zuylen, Sravanthi Parasa, Sameer Singh, Matt Gardner, and Hannaneh Hajishirzi. Mediat: A dataset of medical images, captions, and textual references. arXiv preprint arXiv:2010.06000, 2020. 1, 5
- [29] Tim Tanida, Philip M’uller, Georgios Kaissis, and Daniel Rueckert. Interactive and explainable region-guided radiology report generation. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pages 7433–7442, 2023. 1
- [30] Ashish Vaswani, 否am Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention is all you need. Advances in neural information processing systems, 30, 2017. 3
- [31] Petar Velićković, Guillem Cucurull, Arantxa Casa 否va, Adriana Romero, Pietro Lio, and Yoshua Bengio. Graph attention networks. arXiv preprint arXiv:1710.10903, 2017. 4
- [32] Zichao Yang, Xiaodong He, Jianfeng Gao, Li Deng, and Alex Smola. Stacked attention networks for image question answering. In Proceedings of the IEEE conference on computer vision and pattern recognition, pages 21–29, 2016. 1
- [33] Anda Zhang, Wei Tao, Ziyang Li, Haofen Wang, and Wenqiang Zhang. Type-aware medical visual question answering. In ICASSP 2022-2022 IEEE International Conference on Acoustics, Speech and Signal Processing, pages 4838–4842. IEEE, 2022. 1, 2
- [34] Xiaoman Zhang, Chaoyi Wu, Ziheng Zhao, Weixiong Lin, Ya Zhang, Yanfeng Wang, and Weidi Xie. Pmc-vqa: Visual instruction tuning for medical visual question answering. arXiv preprint arXiv:2305.10415, 2023. 3, 6
- [35] Yubo Zhang, Xingxing Zhang, Xun Wang, Siqing Chen, and Furu Wei. Latent prompt tuning for text summarization, 2022. 1, 2
- [36] Jie Zhou, Ganqu Cui, Shengding Hu, Zhengyan Zhang, Cheng Yang, Zhiyuan Liu, Lifeng Wang, Changcheng Li, and Maosong Sun. Graph neural networks: A review of methods and applications. AI open, 1:57–81, 2020. 4
- [37] Kaiyang Zhou, Jingkang Yang, Chen Change Loy, and Ziwei Liu. Conditional prompt learning for vision-language models. In Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, pages 16816–16825, 2022. 2
- [38] Kaiyang Zhou, Jingkang Yang, Chen Change Loy, and Ziwei Liu. Learning to prompt for vision-language models. International Journal of Computer Vision, 130(9):2337–2348, 2022. 2

